

Informe técnico de optimización, regularización y evaluación final Fashion-MNIST

Cesar Rojas

20 de septiembre de 2026

1. Alcance y protocolo

Esta etapa recibe como control la MLP [256, 128], ReLU, Softmax, categorical crossentropy, SGD con learning rate 0,1, batch 128, 20 épocas y seed 42. El objetivo es estudiar optimizadores y regularización mediante experimentos controlados, congelar una configuración usando solo validation y evaluar test una única vez.

Se conservó el split estratificado de 54.000 ejemplos de train y 6.000 de validation. El test oficial permaneció sellado durante E6–E9. Las decisiones usan Accuracy, F1 Macro, curvas de validation y gaps train–validation; test se consulta solamente después de F0.

2. E6 y E6b: optimizadores

E6 cambió únicamente el optimizador bajo learning rate común 0,1. SGD fue el control más estable; el rendimiento bajo de Adam y RMSProp no se interpretó como una descalificación general, sino como evidencia de que esa escala de LR no era adecuada. E6b cambió solamente el LR de cada adaptativo a 0,001.

ID	Optimizador / LR	Accuracy	F1 Macro	Gap acc.	Gap loss
E6	SGD / 0,1	0,8952	0,8954	0,0287	0,0851
E6	RMSProp / 0,1	0,1985	0,0684	—	—
E6	Adam / 0,1	0,4722	0,4166	—	—
E6b	Adam / 0,001	0,8912	0,8916	0,0527	0,1941
E6b	RMSProp / 0,001	0,8933	0,8929	0,0476	0,2165

Cuadro 1: E6 y E6b sobre validation.

SGD conserva la mejor Accuracy y F1 Macro, además de gaps menores que los optimizadores retuneados. Se seleccionó como control provisional para E7; todavía no se usó test ni se congeló la configuración.




Figura 1: Curvas de validation para E6b.

3. E7–E9: regularización

E7 varía exclusivamente Dropout. E8 cambia únicamente Batch Normalization y aplica el orden Dense lineal → Batch Normalization → ReLU → Dropout. E9 cambia solamente la fuerza L2. De esta forma no se atribuyen a una técnica efectos que puedan corresponder a otra.

Etapa	Cambio único	Accuracy	F1 Macro	Gap acc.	Gap loss
E7	Dropout 0,0	0,8952	0,8954	0,0287	0,0851
E7	Dropout 0,2	0,8997	0,8997	0,0021	0,0135
E8	BatchNorm OFF	0,8997	0,8997	0,0021	0,0135
E8	BatchNorm ON	0,8922	0,8911	0,0294	0,0827
E9	L2 0	0,8997	0,8997	0,0021	0,0135
E9	L2 10^{-4}	0,8967	0,8970	0,0025	0,0102

Cuadro 2: Comparaciones controladas de regularización.

Dropout 0,2 mejoró simultáneamente Accuracy/F1 y generalización, por lo que se seleccionó. Batch Normalization no compensó su costo ni sus gaps mayores en este régimen. L2 redujo marginalmente el gap de loss, pero no mejoró Accuracy ni F1 y su loss incorpora la penalización. Estos dos resultados negativos son contextuales: no afirman que BatchNorm o L2 sean inútiles en general.




Figura 2: Curvas de validation que respaldan las decisiones E7 y E9.

4. F0: congelamiento

La decisión L2 se repitió con seed 7: sin L2 obtuvo Accuracy 0,8902 frente a 0,8863 con L2 10^{-4} . Los promedios locales fueron 0,8949 sin L2 y 0,8915 con L2. Una revisión externa observó una diferencia marginal e inversión en otra ejecución, por lo que L2 cero se conserva como opción prudente y trazable, sin afirmar estabilidad robusta entre entornos. Early Stopping no se implementó porque el control alcanzó su mejor validation accuracy y loss al final de las 20 épocas, sin deterioro sostenido ni ahorro material.

Por tanto, F0 congeló la MLP [256,128], ReLU, Softmax, categorical crossentropy, SGD LR 0,1, batch 128, 20 épocas, seed 42, Dropout 0,2 y sin Batch Normalization, L2 ni Early Stopping. Después de esta decisión no se ajustó ningún parámetro tras observar test.

5. F1: evaluación final única

La configuración congelada se entrenó con train 54.000/validation 6.000 y se evaluó una única vez sobre los 10.000 ejemplos oficiales de test. El registro decisorio conserva el hash de F0 y las versiones del entorno; el notebook de Colab lo presenta sin volver a consultar test.

Métrica	Test
Accuracy	0,8838
Precision Macro	0,8844
Recall Macro	0,8838
F1 Macro	0,8836
Precision ponderada	0,8844
Recall ponderado	0,8838
F1 ponderado	0,8836

Cuadro 3: Métricas globales de F1.

La matriz de confusión evidencia dificultades entre prendas superiores visualmente similares. Shirt fue la clase más difícil (Precision 0,7021, Recall 0,6930 y F1 0,6975), seguida de confusiones entre T-shirt/top, Pullover y Coat. Esta observación se comunica como limitación y no se usa para modificar el modelo.




Figura 3: Matriz de confusión final sobre test.




Figura 4: Ejemplos de errores de menor confianza.

6. Conclusión y reproducibilidad

La etapa demuestra que Dropout 0,2 aportó la mejora de generalización más clara bajo el control recibido. SGD LR 0,1 mantuvo el mejor compromiso ante los optimizadores estudiados, mientras que BatchNorm y L2 no mejoraron las métricas en este régimen. La evaluación final obtuvo Accuracy 0,8838 y F1 Macro 0,8836 sin retroalimentar ajustes desde test.

El código reutilizable, las configuraciones, tablas y figuras se mantienen en el repositorio. La versión final pasa 31 pruebas automatizadas y Ruff. La fuente canónica es `src/ep1_fashion_mnist/`; el informe consolidado de las tres etapas se encuentra en `docs/latex/final/main.tex`.