

Informe final integrado

EP1 Deep Learning: Fashion-MNIST

Ignacio Silva

Lucas Moncada

Cesar Rojas

20 de septiembre de 2026

Resumen

Este informe integra el trabajo completo del proyecto: preparación de datos y baseline, estudio de funciones, hiperparámetros y arquitectura, y análisis de optimización, regularización y evaluación final. La configuración se seleccionó exclusivamente mediante validation, se congeló antes de consultar test y obtuvo Accuracy 0,8838 y F1 Macro 0,8836 en la evaluación final única.

1. Objetivo y metodología

Se entrenó una red neuronal multicapa para clasificar las diez clases de Fashion-MNIST. El diseño experimental fue secuencial y controlado: cada experimento modifica una variable respecto de un control explícito. La selección usa Accuracy, Precision, Recall y F1 en variantes macro y ponderada, curvas de train/validation, gaps de generalización, cantidad de parámetros y costo local cuando corresponde.

El train oficial se dividió de forma estratificada con seed 42 en 54.000 ejemplos de train y 6.000 de validation (5.400/600 por clase). El test oficial de 10.000 ejemplos quedó sellado en E0–E9. Solo después de F0 se hizo una predicción sobre test en F1; sus resultados no habilitaron ningún ajuste posterior.

2. Datos, preprocesamiento y baseline — Ignacio

Fashion-MNIST contiene imágenes de 28×28 píxeles en escala de grises. Las imágenes `uint8` en $[0, 255]$ se convierten a `float32` en $[0, 1]$. Las etiquetas se codifican one-hot, coherentes con Softmax y categorical crossentropy. La estratificación conserva la representación de cada clase y hace comparables las métricas de validation.




Figura 1: Distribución balanceada de clases en train.

E0 usa una MLP con `Flatten`, capas ocultas $[256, 128]$ con ReLU, salida Softmax, categorical crossentropy, SGD con learning rate 0,01, batch 128 y 20 épocas. No usa regularización.

Métrica de validation	E0
Accuracy	0,8722
Precision Macro	0,8737
Recall Macro	0,8722
F1 Macro	0,8726
Parámetros	235.146

Cuadro 1: Baseline E0 sobre validation.




Figura 2: Curvas de train y validation de E0.

2.1. Activación y función de pérdida

E1 cambia solamente la activación oculta; E2 cambia solamente la pérdida. ReLU supera a Tanh por 0,78 puntos porcentuales y a Sigmoid por 11,87 puntos de Accuracy. Con ReLU fija, categorical crossentropy supera a MSE por 13,52 puntos. Por ello se conserva ReLU, Softmax y categorical crossentropy para el resto del estudio.

ID	Cambio único	Accuracy	F1 Macro
E0	ReLU + categorical crossentropy	0,8722	0,8726
E1_tanh	Tanh	0,8643	0,8647
E1_sigmoid	Sigmoid	0,7535	0,7490
E2_mse	MSE	0,7370	0,7168

Cuadro 2: Comparaciones controladas E1 y E2.




Figura 3: Efecto de activación y pérdida sobre Accuracy de validation.

3. Hiperparámetros y capacidad — Lucas

E3 compara learning rates 0,001, 0,01 y 0,1. E4 hereda LR 0,1 y compara batch sizes. E5 hereda LR y batch seleccionados y compara capacidad. Esta secuencia evita confundir el efecto de varias variables.

Etapas	Configuración	Accuracy	F1 Macro	Gap loss	Parámetros
E3	LR 0,001	0,8053	0,8034	—	235.146
E3	LR 0,01	0,8722	0,8726	—	235.146
E3	LR 0,1	0,8933	0,8936	—	235.146
E4	Batch 32	0,8860	0,8864	0,2022	235.146
E4	Batch 128	0,8933	0,8936	0,0885	235.146
E4	Batch 512	0,8745	0,8771	0,0303	235.146
E5	[64]	0,8873	0,8881	0,0256	50.890
E5	[256, 128]	0,8933	0,8936	0,0885	235.146
E5	[512, 256, 128]	0,8990	0,8989	0,1215	567.434

Cuadro 3: Resultados E3–E5 de validation.

LR 0,1 mejora 2,12 puntos de Accuracy frente a 0,01. Batch 128 ofrece la mejor métrica con costo intermedio; batch 512 reduce gaps y tiempo, pero pierde 1,88 puntos de Accuracy. La red grande mejora solo 0,57 puntos frente a [256, 128], a cambio de 2,41 veces más parámetros y mayor gap. Se selecciona [256, 128], SGD, LR 0,1 y batch 128 como control equilibrado.




Figura 4: Curvas representativas de E3 y E5.

4. Optimización y regularización — Cesar

4.1. Optimizadores

E6 sustituye únicamente el optimizador con LR común 0,1. RMSProp y Adam no convergen de manera comparable en esa escala, lo que justifica E6b: con cada optimizador fijo, se cambia solamente el LR a 0,001. SGD mantiene el mejor compromiso, por lo que se usa como control de regularización.

ID	Optimizador / LR	Accuracy	F1 Macro	Gap acc.	Gap loss
E6	SGD / 0,1	0,8952	0,8954	0,0287	0,0851
E6	RMSProp / 0,1	0,1985	0,0684	—	—
E6	Adam / 0,1	0,4722	0,4166	—	—
E6b	Adam / 0,001	0,8912	0,8916	0,0527	0,1941
E6b	RMSProp / 0,001	0,8933	0,8929	0,0476	0,2165

Cuadro 4: E6 y E6b sobre validation.




Figura 5: E6b: LR ajustado de forma separada por optimizador.

4.2. Regularización

E7 muestra que Dropout 0,2 eleva Accuracy/F1 a 0,8997 y reduce los gaps de Accuracy/loss a 0,0021/0,0135. E8 activa únicamente Batch Normalization en el orden Dense lineal → BatchNorm → ReLU → Dropout; bajo este control, empeora las métricas y gaps. E9 cambia solo L2: 10^{-4} baja marginalmente un gap de loss, pero no mejora Accuracy ni F1 y la loss incorpora la penalización.

Etapa	Cambio único	Accuracy	F1 Macro	Gap acc.	Gap loss
E7	Dropout 0,0	0,8952	0,8954	0,0287	0,0851
E7	Dropout 0,2	0,8997	0,8997	0,0021	0,0135
E8	BatchNorm OFF	0,8997	0,8997	0,0021	0,0135
E8	BatchNorm ON	0,8922	0,8911	0,0294	0,0827
E9	L2 0	0,8997	0,8997	0,0021	0,0135
E9	L2 10^{-4}	0,8967	0,8970	0,0025	0,0102

Cuadro 5: E7–E9: comparaciones de regularización.




Figura 6: Curvas de validation para Dropout y L2.

5. F0, F1 y análisis final

La decisión L2 se repitió con seed 7: sin L2 obtuvo Accuracy 0,8902 y con L2 0,8863. Los promedios con dos seeds son 0,8949 y 0,8915 respectivamente. No se activa Early Stopping porque el control alcanza su mejor validation accuracy y loss al final de las 20 épocas, sin deterioro sostenido ni ahorro material.

F0 congela: MLP [256, 128], ReLU, Softmax, categorical crossentropy, SGD LR 0,1, batch 128, 20 épocas, seed 42, Dropout 0,2, sin BatchNorm, L2 ni Early Stopping. F1 entrena esta configuración conservando el split 54.000/6.000 y la evalúa una única vez sobre test.

Métrica	Test
Accuracy	0,8838
Precision Macro	0,8844
Recall Macro	0,8838
F1 Macro	0,8836
Precision ponderada	0,8844
Recall ponderado	0,8838
F1 ponderado	0,8836

Cuadro 6: F1: evaluación final única sobre los 10.000 ejemplos oficiales de test.

Clase	Precision	Recall	F1
T-shirt/top	0,8721	0,7980	0,8334
Trouser	0,9898	0,9700	0,9798
Pullover	0,7958	0,7990	0,7974
Dress	0,8394	0,9250	0,8801
Coat	0,8030	0,8070	0,8050
Sandal	0,9795	0,9550	0,9671
Shirt	0,7021	0,6930	0,6975
Sneaker	0,9238	0,9700	0,9463
Bag	0,9710	0,9720	0,9715
Ankle boot	0,9674	0,9490	0,9581

Cuadro 7: Métricas por clase en F1. Shirt es la clase más difícil.




Figura 7: Matriz de confusión final. Las confusiones se concentran en prendas superiores visualmente similares.




Figura 8: Errores de menor confianza en test; complementan las métricas agregadas.

6. Conclusiones y reproducibilidad

El estudio respalda una MLP compacta y trazable. ReLU, Softmax y categorical crossentropy fueron las funciones adecuadas; LR 0,1 y batch 128 lograron el mejor equilibrio; la arquitectura [256, 128] evitó el incremento desproporcionado de complejidad de la alternativa grande; y Dropout 0,2 fue la mejora de generalización seleccionada. Batch Normalization y L2 no mejoraron bajo estas condiciones, conclusión contextual y no general.

F1 Macro 0,8836 confirma desempeño equilibrado globalmente, pero el análisis por clase revela una limitación importante: Shirt alcanza F1 0,6975 y se confunde con prendas superiores parecidas. Esta evidencia se comunica como limitación; no se usa para modificar el modelo tras test.

La ejecución se reproduce con Python 3.12, `uv sync -frozen` y las versiones bloqueadas en `uv.lock`. El proyecto cuenta con 31 pruebas automatizadas y lint correcto. El notebook final autónomo reúne código, experimentos, gráficos y conclusiones para ejecutarse desde un runtime nuevo de Google Colab.